


戦略コンサルで働くデータサイエンティストのブログ

WRITTEN BY A DATA SCIENTIST WORKING AT A CONSULTING FIRM

プロフィール



ID: **Gin04**
Twitter: **Gin04tw**
GitHub: **Gin04gh**
データ分析業務、予測モデル開発などを担当しています。
勉強してきた技術などを適当に書いていければと思います。
Python、R、SAS、JavaScript、PHP、Rubyらへんが得意です。

最近の投稿

- Bi-LSTM学習におけるバッチごとの系列長調整について 2019-07-07
- 機械学習モデルを解釈する指標SHAPについて 2019-04-26
- WordCloudとpyLDAvisによるLDAの可視化について 2018-12-29
- 因子分析でテニスのサーブカ・リターン力を定量化してみた 2018-11-11
- 文書分散表現SCDVと他の分散表現を比較してみた 2018-10-12
- クレジットカード不正利用予測モデルを作成・評価してみた 2018-09-24
- 分析環境をコンテナ管理するようにしてみた 2018-09-05
- 数学ガールシリーズを読んだ 2018-08-19

人気の投稿

- 白線の教師なしセマンティックセグメンテーションを頑張ってみた
- 機械学習モデルを解釈する指標SHAPについて
- PyTorchでニューラルネットワーク、RNN、CNNを実装してみた
- 文書分散表現SCDVと他の分散表現を比較してみた
- PyTorchで深層強化学習（DQN、DoubleDQN）を実装してみた
- 統計検定準1級の試験対策について
- インタラクティブなグラフ生成ライブラリPlotlyについて
- 深層強化学習でシステムトレードしてみたかった
- 統計検定2級の試験対策について
- WordCloudとpyLDAvisによるLDAの可視化について

畳み込みニューラルネットワークで為替予測してみたかった

📅 2017-10-13
🏷 Python, 深層学習

タイトルの通り、為替データを畳み込みニューラルネットワーク（CNN）で読み込んで予測させるまでを、Chainerで実装してみました。

今回は順を追って、データの取得と加工、モデルの構築、学習と予測をしていきます。

まずは為替のデータの取得です。

Pythonのライブラリ `pandas_datareader` を使って、日付ごとのドル円価格のデータを取得しました。

期限は適当に区切って、7年分を取得してきています。

```
1 import numpy as np
2 import pandas as pd
3 from pandas_datareader import data, wb
4
5 start = "2010-08-01"
6 end = "2017-08-01"
7 usdjpy = data.DataReader("DEXJPUS", "fred", start, end) # ドル円レート from セントルイス連邦準備銀行
8 display(usdjpy.head())
9
```

	DEXJPUS
DATE	
2010-08-02	86.42
2010-08-03	85.88
2010-08-04	86.26
2010-08-05	85.83
2010-08-06	85.25

いったん様子を確認するため、プロットしてみます。

```
1 import matplotlib
2 import matplotlib.pyplot as plt
3 matplotlib.style.use("ggplot")
4
5 # 原系列プロット
6 usdjpy_tmp = usdjpy.dropna()
7 usdjpy_tmp.plot(color="cyan", figsize=(15,7))
8 plt.show()
9
```




さて、この時系列のデータから、ある程度、値の動きを読み込ませた後にその次の値は上がるか・下がるかの予測をできるかどうか、モデルを構築して試してみます。

方法としては、ある程度の時系列の長さを決め、その間の値の上がり具合・下がり具合を数値化したものをCNNで読み込んで、次は「上がる」か「下がる」の分類モデルを構築することにします。

まずは原系列から差分系列に変換し、上下の具合を数値化するため、[0,1]区間に正規化します。

```
1 from sklearn.preprocessing import MinMaxScaler
2
3 # データ加工
4 scaler = MinMaxScaler(feature_range=(0,1))
5 usdjpy_tmp = usdjpy.dropna()
6 usdjpy_tmp = usdjpy_tmp.diff().dropna() # 差分（変動）の系列にする
7 usdjpy_tmp = np.array(usdjpy_tmp["DEXJPUS"].values).reshape(-1,1) # numpy配列にする
8 usdjpy_tmp = scaler.fit_transform(usdjpy_tmp) # 正規化
9 plt.figure(figsize=(15,7))
10 plt.plot(usdjpy_tmp, color="cyan")
11 plt.show()
12
```



次に、CNNで読み込める教師データの形にします。

系列データから決めた時系列の長さ分だけ取得してきて、入力を上下の具合を1次元の画像と見立てたもの、出力を1（上がる）か0（下がる）に変換していきます。

```

1 SEQ_SIZE = 50
2
3 dataset = []
4 for i in range(len(usdjpy_tmp)-SEQ_SIZE): # SEQ_SIZE分の系列をとり、その次の値が上がっているか下がっているかのラベルにする
5     x = usdjpy_tmp[i:i+SEQ_SIZE]
6     t_tmp = usdjpy_tmp[i+SEQ_SIZE]
7     t = 1 # 上がっている
8     if x[-1] > t_tmp: # 下がっている
9         t = 0
10    x = np.array(x, dtype="float32").reshape(1, 1, SEQ_SIZE) # 畳み込みニューラルネットワークにするので、時系列は1次元の画像と見立てる (in_channel, height_size, width_size)
11    t = np.array(t, dtype="int32")
12    dataset.append((x, t))
13 N = len(dataset)
14
15 print("教師データ件数: ", N)
16
17 # 一部確認してみる
18 for i in range(5):
19     print(dataset[i][0][0])
20     plt.figure(figsize=(30, 140))
21     plt.imshow(dataset[i][0][0], cmap="gray")
22     plt.show()
23

```

教師データ件数: 1704

```
[[ 0.44927537 0.5826087 0.46521738 0.44347826 0.61884058 0.52753621
  0.45217392 0.59565216 0.58115941 0.40144926 0.5536232 0.49855071
  0.52173913 0.57971013 0.45942029 0.38260868 0.58550727 0.53478259
  0.59855074 0.46521738 0.44492754 0.5826087 0.47971013 0.57101446
  0.42608696 0.54202896 0.5246377 0.57101446 0.44057971 0.45797101
  0.90144926 0.54057974 0.53478259 0.52318841 0.47246376 0.38405797
  0.52028984 0.51594204 0.51739132 0.47681159 0.49710146 0.51594204
  0.49420291 0.53188407 0.5043478 0.47391304 0.46231884 0.45652175
  0.51014495 0.53768116]]
```



```
[[ 0.5826087 0.46521738 0.44347826 0.61884058 0.52753621 0.45217392
  0.59565216 0.58115941 0.40144926 0.5536232 0.49855071 0.52173913
  0.57971013 0.45942029 0.38260868 0.58550727 0.53478259 0.59855074
  0.46521738 0.44492754 0.5826087 0.47971013 0.57101446 0.42608696
  0.54202896 0.5246377 0.57101446 0.44057971 0.45797101 0.90144926
  0.54057974 0.53478259 0.52318841 0.47246376 0.38405797 0.52028984
  0.51594204 0.51739132 0.47681159 0.49710146 0.51594204 0.49420291
  0.53188407 0.5043478 0.47391304 0.46231884 0.45652175 0.51014495
  0.53768116 0.47391304]]
```



```
[[ 0.46521738 0.44347826 0.61884058 0.52753621 0.45217392 0.59565216
  0.58115941 0.40144926 0.5536232 0.49855071 0.52173913 0.57971013
  0.45942029 0.38260868 0.58550727 0.53478259 0.59855074 0.46521738
  0.44492754 0.5826087 0.47971013 0.57101446 0.42608696 0.54202896
  0.5246377 0.57101446 0.44057971 0.45797101 0.90144926 0.54057974
  0.53478259 0.52318841 0.47246376 0.38405797 0.52028984 0.51594204
  0.51739132 0.47681159 0.49710146 0.51594204 0.49420291 0.53188407
  0.5043478 0.47391304 0.46231884 0.45652175 0.51014495 0.53768116
  0.47391304 0.51014495]]
```



```
[[ 0.44347826 0.61884058 0.52753621 0.45217392 0.59565216 0.58115941
  0.40144926 0.5536232 0.49855071 0.52173913 0.57971013 0.45942029
  0.38260868 0.58550727 0.53478259 0.59855074 0.46521738 0.44492754
  0.5826087 0.47971013 0.57101446 0.42608696 0.54202896 0.5246377
  0.57101446 0.44057971 0.45797101 0.90144926 0.54057974 0.53478259
  0.52318841 0.47246376 0.38405797 0.52028984 0.51594204 0.51739132
  0.47681159 0.49710146 0.51594204 0.49420291 0.53188407 0.5043478
  0.47391304 0.46231884 0.45652175 0.51014495 0.53768116 0.47391304
  0.51014495 0.5043478 ]]
```

一部データを確認してみたものが上記となります。

上記のように、値がどう動いてきたかを色の濃淡の画像で表す感じになります。

途中とても白い部分がありますが、ここが原系列の中でもかなり大きく値が変動した部分となっているようです。

実際の値を確認してみると、0.90144926 がその箇所のようです。

これを分類するCNNをChainerで組んでいきます。

入力する画像（時系列）は縦方向の次元が1次元となっていますので、フィルターの縦サイズは1とし、横サイズは適当に決めることにします。

出力層の次元数は、1（上がる）か0（下がる）なので2です。

```
1 import chainer
2 from chainer import Chain, optimizers, training
3 from chainer.training import extensions
4 import chainer.functions as F
5 import chainer.links as L
6
7 # CNNクラスの定義
8 class CNN(Chain):
9     def __init__(self):
10         # クラスの初期化
11         super(CNN, self).__init__(
12             conv1 = L.Convolution2D(1, 20, (1,5)),
13             conv2 = L.Convolution2D(20, 50, (1,5)),
14             l1 = L.Linear(500, 100),
15             l2 = L.Linear(100, 100),
16             l3 = L.Linear(100, 2)
17         )
18
19     def __call__(self, x):
20         # 順伝播の計算を行う関数
```

```

21 # :param x: 入力値
22 h = F.max_pooling_2d(F.relu(self.conv1(x)), 2)
23 h = F.max_pooling_2d(F.relu(self.conv2(h)), 2)
24 h = F.relu(self.l1(h))
25 h = F.relu(self.l2(h))
26 y = self.l3(h)
27 return y
28

```

上記のように、畳み込み層2層 + 全結合3層のモデルを用意しました。

これに先ほど作成した教師データから、学習用、テスト用に分割し、学習と予測精度の評価をしてみます。

学習の実装が下記になります。

```

1 EPOCH_NUM = 30
2 BATCH_SIZE = 200
3
4 # モデルの定義
5 model = L.Classifier(CNN())
6 optimizer = optimizers.Adam()
7 optimizer.setup(model)
8
9 # 学習開始
10 print("Train")
11 train, test = chainer.datasets.split_dataset_random(dataset, N-100)
12 train_iter = chainer.iterators.SerialIterator(train, BATCH_SIZE)
13 test_iter = chainer.iterators.SerialIterator(test, BATCH_SIZE, repeat=False, shuffle=False)
14 updater = training.StandardUpdater(train_iter, optimizer, device=-1)
15 trainer = training.Trainer(updater, (EPOCH_NUM, "epoch"), out="result")
16 trainer.extend(extensions.Evaluator(test_iter, model, device=-1))
17 trainer.extend(extensions.LogReport())
18 trainer.extend(extensions.PrintReport( ["epoch", "main/loss", "validation/main/loss", "main/accuracy", "validation/main/accuracy", "elapsed_time"])) # エポック
19 #trainer.extend(extensions.ProgressBar()) # ログレスバー出力
20 trainer.run()
21

```

Train epoch	main/loss	validation/main/loss	main/accuracy	validation/main/accuracy	elapsed_time
1	0.6945	0.696726	0.512778	0.5	0.368694
2	0.69371	0.693894	0.51125	0.5	0.668306
3	0.693992	0.69406	0.501875	0.5	0.960832
4	0.693212	0.693427	0.48125	0.5	1.24069
5	0.692661	0.693507	0.50125	0.49	1.59873
6	0.692001	0.693523	0.53625	0.52	1.91426
7	0.69139	0.69376	0.533125	0.43	2.23604
8	0.68936	0.693013	0.531875	0.47	2.53556
9	0.686648	0.691831	0.55875	0.53	2.86279
10	0.683469	0.691232	0.55625	0.53	3.18392
11	0.681901	0.684926	0.5675	0.53	3.49856
12	0.66974	0.684411	0.62375	0.57	3.8214
13	0.658943	0.680541	0.619375	0.58	4.15561
14	0.636122	0.67823	0.659375	0.55	4.46374
15	0.619519	0.689253	0.66	0.62	4.74584
16	0.600674	0.691189	0.665625	0.62	5.05895
17	0.602458	0.671296	0.675625	0.64	5.36039
18	0.565715	0.673815	0.71125	0.65	5.64803
19	0.557535	0.673052	0.720625	0.65	5.93639
20	0.565635	0.68234	0.700625	0.62	6.30144
21	0.556392	0.672347	0.700625	0.62	6.62216
22	0.566502	0.668243	0.7	0.65	6.92982
23	0.539419	0.67359	0.7425	0.66	7.22881
24	0.516406	0.665725	0.7425	0.67	7.55725
25	0.520564	0.666941	0.7325	0.66	7.85159
26	0.503979	0.683632	0.75125	0.63	8.14055
27	0.506206	0.663624	0.74625	0.7	8.43634
28	0.484892	0.655963	0.7625	0.69	8.72336
29	0.477316	0.693221	0.77	0.63	9.00791
30	0.479508	0.691833	0.765	0.67	9.3656

テストデータに対して、7割近くまで当てられるようになりました。

個人的には、思っていた以上に当たっていて、びっくりしています笑

こうしてニューラルネットワークである程度予測できるということは、やはり何かしら規則的なものがあるのでしょうか。

素人からすると次が上がるか下がるかなんて全く予測できませんが、経験多く積んだ投資家や専門家から見ると、少なくともこの程度の精度以上には当てられるのかもしれない。

株価の世界などで俗に言われるテクニカル分析というものが、レート（レート）の形から将来の値動きを予測する手法と言われているので、何かしら予測する方法があるのだらうと思います。

ところで、今回はCNNを使いましたが、こういった時系列データはむしろ再帰的ニューラルネットワーク（RNN）の方が合っているのではないかと思います。実はRNNでも試しており、同程度の予測率が出せることが確認できています。

ただしRNNですと、やはり計算量が大きくなりがちですので、より早いモデルとしてCNNを使った場合はどうなるのかの検証のため、今回はCNNを試してみたといったところですね。

フィルタで読み取った上でマックスプーリングして、ある程度、事前の系列を集約してしまった上でも、先ほどのような規則的なものが現れると考えると良さそうです。

追記（2017-12-16）

記事を作成した時は「絶対何か間違いがあるだろうなー」とは思っていたのですが、やはり正しくないことをしていたようです。

下記の突っ込みコメントをいただきました。

テスト用データを作る際に、ランダムに分離していますが、元のデータは時系列データにウィンドウをスライドしながら作ったものなので、テスト用データの中に、「学習データと1つずれただけ」のような、学習データと部分的に被るデータが多数含まれる事になります。そのため、元のデータにMomentumが存在するとき、結果が不正確に高く評価されると思います。

なるほど涙

データをスライドしながら作成するまではともかく、学習と評価にそれを混ぜてしまっていました。

そうなると、部分的に全く一緒のデータを予測することになってしまい、学習で入力された結果と同じものをそのまま返すようになってしまっています。

これ、直に「値」を予測していれば、もっとすごく当たっているような、変な結果が導かれることになりそうですね。

となると予測問題とするには、完全に切り分けるか、長い間系列を予測させ続けるか、遠い先の値を予測するかといった形になるのだろうか。

時系列って難しいですね…。

タイトルも改め、「してみたかった」に変更しました。

コメントしていただいた方、ありがとうございました。

0

“畳み込みニューラルネットワークで為替予測してみたかった” への 0 件のフィードバック

コメントを残す

メールアドレスが公開されることはありません。 * が付いている欄は必須項目です

コメント

名前 *

メールアドレス *

サイト

- ☐ 新しいコメントをメールで通知
- ☐ 新しい投稿をメールで受け取る

コメントを送信

Twitter



Gin04

@Gin04tw

割と最近SQLできないデータサイエンティスト見かけるようになってきてて、まじかって思う。

2020年1月31日

Gin04さんがリツイートしました



TJO

@TJO_datasci

SQL書けないデータサイエンティストの皆さん、黒魔術本を買って辞書代わりに脇に常におきましょう [tjo.hatenablog.com/entry/2017/04/...](https://tjo.hatenablog.com/entry/2017/04/)

埋め込む

Twitterで表示

管理人執筆の本



たのしいベイズモデリング2

posted with ヨメレバ

豊田 秀樹/武藤 拓之 北大路書房 2019年11月18日

楽天ブックス

Amazon

アーカイブ

月を選択

カテゴリー

- JavaScript (12)
- Python (36)
- R (1)
- Ruby (2)
- データ分析 (12)
- データ可視化 (21)
- 強化学習 (4)
- 未分類 (10)
- 深層学習 (20)

まとめ投稿

- Pythonによる仮説検定まとめ
- Pythonによる区間推定まとめ
- Rによる仮説検定まとめ
- Rによる区間推定まとめ
- 強化学習の勉強でおすすめの書籍まとめ
- 時系列分析の勉強でおすすめの書籍まとめ
- 深層学習の勉強でおすすめの書籍まとめ
- 統計学や機械学習の勉強でおすすめの書籍まとめ
- 自然言語処理の勉強でおすすめの書籍まとめ

検索 ...

Q

スポンサーリンク

プライバシーポリシー

・掲載されている広告について

当サイトでは、第三者配信の広告サービス（Googleアドセンス）を利用しています。

このような広告配信事業者は、ユーザーの興味に応じた商品やサービスの広告を表示するため、

当サイトや他サイトへのアクセス情報（『Cookie』（氏名、住所、メール アドレス、電話番号は含まれません））を使用することがあります。

Googleアドセンスに関する詳細やこのような情報が広告配信事業者に使用されないようにする方法については、[こちら](#)をご参照ください。

・使用しているアクセス解析ツールについて

当サイトでは、Googleによるアクセス解析ツール「Googleアナリティクス」を利用しています。

このGoogleアナリティクスはトラフィックデータの収集のために『Cookie』を使用しています。

このトラフィックデータは匿名で収集されており、個人を特定するものではありません。

また『Cookie』を無効にすることで収集を拒否することが出来ますので、お使いのブラウザの設定をご確認ください。

この規約に関して、詳しくは[こちら](#)をご覧ください。